5-10算法整理

更新目标不一样 MC更新的是完整的GT 而TD是Rt+1+γV(St+1)所以不需要等episode结束自然是bootstrap

Monte Carlo Methods

MC prediction
更新对象：状态价值表 **V(s)**
更新信号：完整 episode return G_t
特点：必须等 episode 结束；不 bootstrap。

用同样的东西(Gt) 近似两个看似不同的东西（V/Q）

MC prediction 是"评价当前策略"。MC control 是"评价动作，并让策略越来越倾向于好动作"

MC control
更新对象：动作价值表 **Q(s,a)**
更新信号：完整 episode return G_t
特点：先用完整回报评价动作，再用 ϵ -greedy 改策略。

第一步：按照当前策略 π 跑完整个 episode （同上）
第二步：episode 结束后，从后往前算回报 G（同上）
第三步：关键变化：更新的是 $Q(St, At)$

Robbins-Monro

更新对象：一个未知期望或方程根的估计 w
更新信号：样本噪声下的误差。
特点：它不是一个具体 RL 算法，而是后面 TD / SGD 的数学骨架。

Temporal-Difference Methods

TD(0) state-value
更新对象：状态价值表 V(s)
更新信号：一步 TD error。
特点：不等 episode 结束；使用 bootstrap。

我现在在状态 S，按照固定策略 π 选一个动作，走一步，得到奖励 R，进入下一个状态Snext
然后我立刻用 R+γV(Snext) 来修正当前状态 V(S)。

从v到q

Sarsa，更新 q(s,a)
更新对象：动作价值表 Q(s,a)
更新信号：下一步真实采取动作带来的 TD target。
特点：on-policy；target 里用的是实际下一动作 A_{t+1}。

Sarsa 的关键是：A_next 真的来自当前ϵ-greedy 策略，所以它学的是当前策略自己的 $q_\pi(s,a)$。如果 Q 变了，下一次 ϵ-greedy 选动作的概率也会变，这就是边评估边改进。

抽到vs当前策略平均

Expected Sarsa
更新对象：动作价值表 Q(s,a)
更新信号：下一状态下按当前策略求期望的 TD target。
特点：仍然是 on-policy，但不用一个实际 A_next，而是对所有动作加权平均。

n-step Sarsa
更新对象：动作价值表 Q(s,a)
更新信号：前 n 步真实奖励，加上第 n 步后的 bootstrap。
特点：介于 one-step Sarsa 和 Monte Carlo 之间

当 n=1，它就是 Sarsa；当 n 接近 episode 长度，它就越来越像 MC。

Q-learning
更新对象：动作价值表 Q(s,a
更新信号：下一状态最大动作价值。
特点：off-policy；采样可以探索，但 target 假设下一步选 greedy action。

它和 Sarsa 的实际区别非常小，但意义很大：
Sarsa target: R + gamma * Q(S_next, A_next)
Q-learning target:R + gamma * max_a Q(S_next, a)

semi-gradient TD
更新对象：参数 w，不是单个表项。
更新信号：TD error。
特点：一个参数可能影响很多状态的估计值。

时间顺序来看 这部分是后续章节引入

从v到q

semi-gradient Sarsa
更新对象：动作价值函数参数 w
更新信号：Sarsa TD error。
特点：把表格 Q(S,A) 换成函数 $\hat q(S,A,w)$。

时间顺序来看 这部分是后续章节引入

Value Function Methods

DQN
更新对象：Q 网络参数 w
更新信号：Q-learning target，但 target 用另一个慢更新网络 w^-计算。
特点：experience replay + target network。

Policy Gradient Methods

到这 我们从前面的 value-based 方法 转到 policygradient方法了。前面那些 TD、SARSA、DQN 主要是在学：V(s), Q(s,a) ，然后通过价值函数间接选动作。

而 REINFORCE 直接学策略：π(a | s,θ)，也就是：神经网络直接输出每个动作的概率，然后更新策略参数 θ，让高回报动作出现概率更大

REINFORCE
更新对象：策略参数 θ。
更新信号：完整 return G_t。
特点：不更新 value table；直接提高好动作的概率。

REINFORCE with baseline
更新对象：策略参数 θ，以及 baseline/value 参数 w
更新信号：G_t-b(S_t,w)
特点：baseline 不改变期望方向，但降低方差。

actor-critic

Q actor-critic
更新对象：critic 参数 w和 actor 参数 \theta
更新信号：critic 给出的 q(S,A,w)
特点：actor 不等完整 episode return，而是用 critic 的估计当质量信号

advantage actor-critic / A2C
更新对象：critic 的 w 和 actor 的 \theta
更新信号：TD error δ_t，它可以看成一步 advantage 估计。
特点：critic 的 TD error 同时服务两个角色：更新 critic，也更新 actor。

advantage

off-policy actor-critic
更新对象：critic 参数 w 和 actor 参数 θ。
更新信号：带 importance ratio 的 TD / policy-gradient signal。
特点：数据由 behavior policy b 生成，但 actor 想更新 target policy π_θ。

deterministic policy gradient / DPG
更新对象：actor 参数 θ 和 critic 参数 w。
更新信号：critic 对动作的梯度 $\nabla_a q(s,a,w)$。
特点：actor 不输出动作概率，而是直接输出动作。